



## سؤال دوم — سطح متوسط

### پیش‌بینی تقاضای اجاره‌ی دوچرخه (Bike Sharing Demand)

| زمان پیشنهادی حل | سطح دشواری |
|------------------|------------|
| ۲ تا ۲.۵ ساعت    | متوسط      |

#### ۱. ایده و زمینه‌ی مسئله

شرکت‌کنندگان باید با استفاده از اطلاعات تاریخی یک سیستم اشتراک دوچرخه، مدلی برای پیش‌بینی تعداد دوچرخه‌های اجاره‌شده در هر ساعت طراحی کنند. در کنار تاریخ و ساعت، ویژگی‌هایی مانند فصل، وضعیت آب‌وهوا، دما، رطوبت، سرعت باد و کاری/تعطیل بودن روز نیز در اختیار شماست. هدف، استفاده از روش‌های یادگیری ماشین برای پیش‌بینی میزان تقاضا در شرایط مختلف است.

#### ۲. صورت مسئله

فرض کنید به‌عنوان دانشمند داده در یک شرکت ارائه‌دهنده‌ی خدمات اشتراک دوچرخه فعالیت می‌کنید. این شرکت می‌خواهد با تکیه بر داده‌های تاریخی، میزان تقاضای دوچرخه را در ساعات مختلف روز پیش‌بینی کند. تعداد دوچرخه‌های اجاره‌شده در هر ساعت می‌تواند تحت تأثیر عواملی مانند ساعت روز، روز هفته، فصل، وضعیت آب‌وهوا، دما، رطوبت و کاری/تعطیل بودن روز باشد.

داده‌ی `train.csv` شامل رکوردهای تاریخی به همراه مقدار واقعی تعداد اجاره (count) است. وظیفه‌ی شما طراحی و آموزش 3 مدل منتخب و ارزیابی انتخاب بهترین آنها بعنوان مدل برتر و سپس پیش‌بینی مقدار count برای رکوردهای `test.csv` است. روش حل به شما تحمیل نشده؛ انتخاب `feature engineering`، `preprocessing`، الگوریتم و نحوه‌ی آموزش بر عهده‌ی شماست. هدف اصلی، ارائه‌ی یک راه‌حل منطقی، قابل دفاع و متناسب با زمان محدود مسابقه است — نه لزوماً بهترین امتیاز ممکن.

#### ۳. داده‌ها

#### نام فایل دیتاست پیوست : bike-sharing-demand

فایل `train.csv` دارای ستون‌های زیر است (شامل ستون هدف count):

| توضیح                                  | ستون         |
|----------------------------------------|--------------|
| شناسه‌ی یکتای رکورد                    | id           |
| تاریخ و ساعت ثبت رکورد                 | datetime     |
| فصل سال                                | season       |
| تعطیل بودن روز                         | holiday      |
| کاری بودن روز                          | workingday   |
| وضعیت آب‌وهوا                          | weather      |
| دمای ثبت‌شده / دمای احساس‌شده          | temp / atemp |
| میزان رطوبت                            | humidity     |
| سرعت باد                               | windspeed    |
| تعداد دوچرخه‌های اجاره‌شده (متغیر هدف) | count        |

فایل `test.csv` همان ستون‌ها را دارد. ستون count نیز در این فایل وجود دارد، اما فقط برای محاسبه‌ی نهایی معیار ارزیابی در اختیار شما قرار گرفته و استفاده از آن در آموزش مدل یا `feature engineering` مجاز نیست.

⚠ **نکته‌ی مهم برای اعتبارسنجی:** برای تنظیم مدل و مقایسه‌ی مدل‌های کاندید، از یک بخش از train.csv به‌عنوان اعتبارسنجی (validation) استفاده کنید، از روش cross validation هم می‌توانید استفاده کنید و بر اساس نتیجه خروجی آن مدل منتخب را شناسایی کنید — فایل test.csv تنها یکبار و در انتهای کار برای گزارش عملکرد نهایی مدل منتخب استفاده می‌شود.

## ۴. خروجی مورد انتظار

فایل خروجی باید با نام دقیق output.csv و با ساختار زیر تولید شود:

| توضیح                                                       | ستون  |
|-------------------------------------------------------------|-------|
| شناسه‌ی یکتای رکورد — دقیقاً مطابق test.csv و با همان ترتیب | id    |
| مقدار پیش‌بینی‌شده توسط مدل                                 | count |

مثال:

|              |
|--------------|
| Id , count   |
| 1001, 152.34 |
| 1002, 187.91 |
| 1003, 94.52  |

⚠ مقدار ستون count باید پیش‌بینی مدل باشد، نه مقدار واقعی کپی‌شده از test.csv. نام فایل، نام ستون‌ها، تعداد و ترتیب رکوردها باید دقیقاً مطابق فرمت اعلام‌شده باشد؛ هرگونه مغایرت می‌تواند باعث از دست رفتن امتیاز این بخش شود.

## ۵. معیار ارزیابی

عملکرد مدل با معیار **Root Mean Squared Logarithmic Error (RMSLE)** سنجیده می‌شود (نیاز به پیاده‌سازی نیست، از کتابخانه‌های آماده (Scikit\_learn) استفاده کنید):

$$RMSLE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\log(p_i + 1) - \log(a_i + 1))^2}$$

که در آن  $p_i$  مقدار پیش‌بینی‌شده،  $a_i$  مقدار واقعی، و  $n$  تعداد نمونه‌هاست. هرچه مقدار RMSLE کمتر باشد، عملکرد مدل بهتر است. مقدار RMSLE را روی test.csv محاسبه و در Notebook گزارش کنید.

## ۶. مراحل پیشنهادی حل (بدون الگوریتم اجباری)

۱. بررسی اولیه‌ی داده‌ها و نوع ویژگی‌ها
۲. بررسی داده‌های گمشده و پرت (outlier)
۳. بررسی توزیع متغیر هدف (count) و در صورت نیاز، بررسی تبدیل لگاریتمی
۴. تحلیل و استخراج ویژگی از datetime (ساعت، روز هفته، ماه، فصل و غیره)
۵. انجام preprocessing موردنیاز (کدگذاری متغیرهای دسته‌ای، مقیاس‌بندی در صورت نیاز)
۶. انتخاب یا ساخت ویژگی‌های جدید در صورت لزوم
۷. انتخاب الگوریتم مناسب و آموزش مدل با استفاده از اعتبارسنجی روی train.csv
۸. انتخاب مدل منتخب بر اساس عملکرد مدل بر روی validation-set (می‌توانید از cross validation یا بخشی از داده‌ی آموزشی را برای ارزیابی مدل‌ها و انتخاب مدل برتر استفاده کنید)
۹. پیش‌بینی نهایی روی test.csv و محاسبه‌ی RMSLE
۱۰. تحلیل نتایج و تولید فایل output.csv

## ۷. تحلیل عملکرد مدل

ارائه‌ی صرف مقدار RMSLE کافی نیست. در ویدیوی خود به سؤالات زیر پاسخ دهید:

- عملکرد مدل چگونه بوده و چه نقاط ضعف/قوتی داشته است؟
- چه عواملی می‌توانند بر میزان خطای مدل تأثیرگذار باشند؟
- کدام ویژگی‌ها را مهم‌تر می‌دانید و چرا؟
- آیا روش دیگری می‌توانست عملکرد بهتری داشته باشد؟
- در صورت داشتن زمان بیشتر، چه تغییراتی در مدل ایجاد می‌کردید؟

## ۸. فایل‌های مورد نیاز برای تحویل

۱. Jupyter Notebook کامل اجرا شده، با خروجی قابل مشاهده‌ی سلول‌ها (تحلیل داده، نمودارها، معیار ارزیابی و نتایج مدل)
۲. ویدیوی حداکثر ۵ دقیقه‌ای  
در ویدیو به‌صورت خلاصه توضیح دهید: تحلیل شما از مسئله، الگوهای مشاهده‌شده در داده، preprocessing انجام‌شده و دلیل آن، ویژگی‌های مهم، مدل انتخابی و دلیل انتخاب، نتیجه‌ی معیار ارزیابی، عوامل مؤثر بر خطای مدل، و در صورت داشتن زمان بیشتر چه بهبودی می‌دادید. نیازی به توضیح خطبه‌خط کد نیست؛ تمرکز ویدیو باید بر منطق حل مسئله و تحلیل نتایج باشد.

**فرم سابمیت پاسخ‌ها:**

بر روی [لینک کلیک کنید](#)