



## سؤال اول — سطح ساده

### پیش‌بینی نجات مسافران (Titanic Survival Prediction)

| سطح دشواری | زمان پیشنهادی حل |
|------------|------------------|
| ساده       | ۱.۵ تا ۲ ساعت    |

#### ۱. ایده و زمینه مسئله

شرکت‌کنندگان باید با استفاده از اطلاعات مسافران کشتی Titanic، مدلی برای پیش‌بینی احتمال زنده‌ماندن مسافران طراحی کنند. داده‌های مورد استفاده شامل اطلاعاتی مانند جنسیت، سن، کلاس بلیت، هزینه بلیت، تعداد اعضای خانوادگی همراه و محل سوار شدن مسافر است. هدف این است که با استفاده از این ویژگی‌ها، وضعیت نهایی مسافران پیش‌بینی شود.

#### ۲. صورت مسئله

فرض کنید به عنوان دانشمند داده در یک شرکت تحلیل داده فعالیت می‌کنید. وظیفه‌ی شما طراحی مدلی است که بتواند بر اساس مشخصات هر مسافر، پیش‌بینی کند که آیا او از حادثه جان سالم به‌در برده است یا خیر.

داده‌ی `train.csv` شامل اطلاعات تعدادی از مسافران به همراه وضعیت نهایی آن‌هاست. داده‌ی `test.csv` نیز شامل اطلاعات گروه دیگری از مسافران است که وضعیت نهایی آن‌ها مشخص نیست. وظیفه‌ی شما آموزش یک مدل یادگیری ماشین با استفاده از `train.csv` و سپس پیش‌بینی وضعیت مسافران `test.csv` است. روش حل به شما تحمیل نشده؛ انتخاب `preprocessing`، ویژگی‌ها، الگوریتم و نحوه‌ی آموزش بر عهده‌ی شماست. هدف اصلی، ساخت مدلی با بیشترین دقت ممکن در چارچوب یک راحل منطقی و قابل دفاع است.

#### ۳. داده‌ها

نام فایل دیتاست پیوست: **titanic**

فایل `train.csv` دارای ستون‌های زیر است (شامل ستون هدف `survived`):

| توضیح                                                                     | ستون     |
|---------------------------------------------------------------------------|----------|
| شناسه‌ی یکتای مسافر                                                       | id       |
| کلاس بلیت مسافر                                                           | pclass   |
| جنسیت مسافر                                                               | sex      |
| سن مسافر                                                                  | age      |
| تعداد خواهر، برادر یا همسر همراه مسافر                                    | sibsp    |
| تعداد والدین یا فرزندان همراه مسافر                                       | parch    |
| هزینه‌ی پرداخت‌شده برای بلیت                                              | fare     |
| محل سوار شدن مسافر                                                        | embarked |
| وضعیت نهایی مسافر (متغیر هدف): ۱ = زنده مانده، ۰ = جان خود را از دست داده | survived |

فایل `test.csv` شامل تمام ویژگی‌های ورودی است، مدل در زمان آموزش این مسافران را ندیده است و شما باید مدل را بر روی داده‌های تست ارزیابی کنید.

**⚠ نکته‌ی مهم برای اعتبارسنجی:** داده‌های `test.csv` نباید در فرآیند آموزش مدل استفاده شوند و صرفاً برای ارزیابی نهایی عملکرد مدل به کار می‌روند.

## ۵. معیار ارزیابی

عملکرد مدل با معیار **Accuracy** سنجیده می‌شود:

$$Accuracy = \frac{\text{Number of correct predictions}}{\text{Number of total predictions}}$$

پیداسازی آن در کتابخانه‌ی scikit-learn موجود است و نیازی به پیداسازی مستقیم معیار نیست. هرچه مقدار Accuracy بیشتر باشد، عملکرد مدل بهتر است. مقدار Accuracy را روی مجموعه‌ی تست خود محاسبه و در Notebook گزارش کنید.

## ۶. مراحل پیشنهادی حل (بدون الگوریتم اجباری)

۱. بارگذاری داده‌ها و بررسی اولیه‌ی آن‌ها
۲. بررسی و مدیریت داده‌های گمشده
۳. تحلیل ویژگی‌ها و ارتباط آن‌ها با متغیر هدف (survived)
۴. انجام preprocessing مناسب (کدگذاری متغیرهای دسته‌ای، مقیاس‌بندی در صورت نیاز)
۵. انتخاب یا ساخت ویژگی‌های مناسب در صورت لزوم
۶. آموزش مدل یادگیری ماشین و گزارش دقت روی داده یادگیری
۷. انجام پیش‌بینی و ارزیابی نهایی روی test.csv

## ۷. تحلیل عملکرد مدل

ارائه‌ی صرفِ مقدار Accuracy کافی نیست. در Notebook خود به‌طور خلاصه به سؤالات زیر پاسخ دهید:

- عملکرد مدل چگونه بوده و چه نقاط ضعف/قوتی داشته است؟
- کدام ویژگی‌ها را در پیش‌بینی زنده‌ماندن مؤثرتر می‌دانید و چرا؟
- در صورت داشتن زمان بیشتر، چه تغییراتی در مدل ایجاد می‌کردید؟

## ۸. فایل‌های مورد نیاز برای تحویل

۱. Jupyter Notebook کامل اجراشده، با خروجی قابل مشاهده‌ی سلول‌ها (نمودارها، جداول، معیار ارزیابی و نتایج مدل)
  ۲. ویدیوی معرفی پروژه حداکثر ۵ دقیقه‌ای — به‌صورت پابلیک در گوگل‌درایو آپلود و لینک آن در فرم پاسخ وارد شود
- در ویدیو به‌صورت خلاصه توضیح دهید: مسئله و هدف پروژه، ساختار داده‌ها، مهم‌ترین مراحل preprocessing، مدل یا مدل‌های استفاده‌شده، معیار ارزیابی و نتیجه‌ی به‌دست‌آمده روی داده‌ی اعتبارسنجی. نیازی به توضیح خطبه‌خط کد نیست؛ تمرکز ویدیو باید بر منطق حل مسئله، تصمیم‌های اصلی و نتایج باشد.

## فرم سابمیت پاسخ‌ها:

بر روی [لینک](#) کلیک کنید