



سؤال سوم — سطح متوسط

پیش‌بینی فروش فروشگاه‌ها (Rossmann Store Sales)

سطح دشواری	زمان پیشنهادی حل
متوسط	۲.۵ ساعت

۱. ایده و زمینه مسئله

دیتاست Rossmann یک مسئله‌ی واقعی forecasting است: فروش روزانه‌ی فروشگاه‌ها به همراه اطلاعاتی مانند تبلیغات (promotion)، نوع فروشگاه و شرایط رقابتی در اختیار شماست. شرکت‌کنندگان باید با استفاده از این اطلاعات تاریخی، مدلی برای پیش‌بینی میزان فروش روزانه‌ی هر فروشگاه طراحی کنند.

۲. صورت مسئله

فرض کنید به عنوان متخصص هوش مصنوعی در یک زنجیره‌ی بزرگ فروشگاه‌های خرده‌فروشی فعالیت می‌کنید. این شرکت تعداد زیادی فروشگاه در نقاط مختلف دارد و می‌خواهد میزان فروش هر فروشگاه را در روزهای آینده پیش‌بینی کند. میزان فروش هر فروشگاه می‌تواند تحت تأثیر عوامل مختلفی باشد؛ از جمله سابقه‌ی فروش فروشگاه، روز هفته، تعطیلات، تبلیغات، نوع فروشگاه، اندازه‌ی فروشگاه و شرایط رقابتی.

داده‌ی train.csv شامل رکوردهای تاریخی به همراه مقدار واقعی فروش (sales) است. وظیفه‌ی شما طراحی و آموزش یک مدل مناسب و سپس پیش‌بینی مقدار sales برای رکوردهای test.csv است. روش حل به شما تحمیل نشده؛

انتخاب preprocessing، feature engineering، الگوریتم و نحوه‌ی آموزش بر عهده‌ی شماست. هدف اصلی، ارائه‌ی یک راه‌حل منطقی و قابل دفاع، متناسب با زمان محدود مسابقه است — نه لزوماً بهترین امتیاز ممکن.

۳. داده‌ها

نام فایل دیتاست پیوست : rossmann-store-sales

فایل train.csv دارای ستون‌های زیر است (شامل ستون هدف sales):

توضیح	ستون
شناسه‌ی یکتای رکورد	id
شناسه‌ی فروشگاه	store
تاریخ	date
شماره‌ی روز هفته	day_of_week
وضعیت فعالیت فروشگاه در آن روز (باز/بسته)	open
برگزاری تبلیغات در آن روز	promo
وضعیت تعطیلات رسمی	state_holiday
برقراری تعطیلات مدارس	school_holiday
نوع فروشگاه	store_type
نوع محصولات ارائه‌شده	assortment
فاصله تا نزدیکترین فروشگاه رقیب	competition_distance
مدت زمان فعالیت رقیب	competition_open_since

توضیح	ستون
میزان فروش (متغیر هدف)	sales

فایل **test.csv** همان ستون‌ها را دارد. ستون sales نیز در این فایل وجود دارد، اما فقط برای محاسبه‌ی نهایی معیار ارزیابی در اختیار شما قرار گرفته و استفاده از آن در آموزش مدل یا feature engineering مجاز نیست.

🔗 **نکته‌ی داده‌ای:** فروشگاه‌های بسته (open=0) معمولاً فروش صفر دارند. بررسی کنید که آیا لازم است این رکوردها را جداگانه مدیریت کنید یا از داده‌های آموزش کنار بگذارید. همچنین ستون‌هایی مانند competition_open_since، competition_distance و promo2_since ممکن است مقادیر گمشده داشته باشند که باید مدیریت شوند.

⚠️ **نکته‌ی مهم برای اعتبارسنجی:** برای تنظیم مدل و مقایسه‌ی روش‌ها، از یک بخش از train.csv به عنوان اعتبارسنجی (validation) استفاده کنید — نه از test.csv. فایل test.csv تنها یکبار و در انتهای کار برای گزارش عملکرد نهایی استفاده می‌شود.

۴. خروجی مورد انتظار

فایل خروجی باید با نام دقیق **output.csv** و با ساختار زیر تولید شود:

توضیح	ستون
شناسه‌ی یکتای رکورد — دقیقاً مطابق test.csv و با همان ترتیب	id
مقدار فروش پیش‌بینی‌شده توسط مدل (عددی غیرمنفی)	sales

مثال:

id	sales
1	5821.40
2	4390.75
3	0.00

⚠️ **مقدار sales باید پیش‌بینی مدل و عددی غیرمنفی باشد،** نه مقدار واقعی کپی‌شده از test.csv. نام فایل، نام ستون‌ها، تعداد و ترتیب رکوردها باید دقیقاً مطابق فرمت اعلام‌شده باشد. وجود رکورد تکراری یا ارائه‌ی چند مقدار برای یک id باعث از دست رفتن کامل امتیاز این بخش می‌شود.

۵. معیار ارزیابی

عملکرد مدل با معیار **Root Mean Squared Logarithmic Error (RMSLE)** سنجیده می‌شود:

$$RMSLE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\log(p_i + 1) - \log(a_i + 1))^2}$$

که در آن p_i مقدار پیش‌بینی‌شده، a_i مقدار واقعی، و n تعداد نمونه‌هاست. هرچه مقدار RMSLE کمتر باشد، عملکرد مدل بهتر است. مقدار RMSLE را روی test.csv محاسبه و در Notebook گزارش کنید (نیازی به محاسبه مستقیم وجود ندارد از کتابخانه‌های آماده استفاده کنید).

۶. مراحل پیشنهادی حل (بدون الگوریتم اجباری)

۱. بررسی اولیه‌ی داده‌ها و نوع ویژگی‌ها
۲. بررسی داده‌های گمشده، به‌ویژه در competition_open_since، competition_distance و promo2_since
۳. بررسی رکوردهای فروشگاه‌های بسته (open=0) و تصمیم‌گیری درباره‌ی نحوه‌ی مدیریت آن‌ها
۴. بررسی توزیع متغیر هدف (sales)

۵. تحلیل و استخراج ویژگی از date (روز هفته، ماه، فصل و غیره)
۶. انجام preprocessing مورد نیاز (کدگذاری متغیرهای دسته‌ای مانند store_type، assortment، state_holiday و نرمالسازی ویژگی‌های عددی)
۷. انتخاب یا ساخت ویژگی‌های جدید در صورت لزوم (مثلاً ترکیب promo و promo2)
۸. انتخاب الگوریتم مناسب و آموزش مدل با استفاده از اعتبارسنجی روی train.csv (با استفاده از train-test split در scikit-learn بخشی از داده آموزشی را برای ارزیابی اولیه (RMSLE) یادگیری مدل و مقایسه مدل‌های کاندید جدا کنید)
۹. پیش‌بینی و ارزیابی نهایی روی test.csv و محاسبه RMSLE مدل منتخب روی داده‌های تست
۱۰. تحلیل نتایج و تولید فایل output.csv

۸. نحوه سابمیت

ارائه‌ی صرف مقدار RMSLE کافی نیست. در ویدیوی توضیحات خود به سؤالات زیر پاسخ دهید:

- عملکرد مدل چگونه بوده و چه نقاط ضعف/قوتی داشته است؟
- چه عواملی می‌توانند بر میزان خطای مدل تأثیرگذار باشند؟
- کدام ویژگی‌ها را مهم‌تر می‌دانید و چرا (مثلاً store_type، promo یا competition_distance)؟
- آیا روش دیگری می‌توانست عملکرد بهتری داشته باشد؟
- در صورت داشتن زمان بیشتر، چه تغییراتی در مدل ایجاد می‌کردید؟

۹. فایل‌های مورد نیاز برای تحویل

۱. Jupyter Notebook کامل اجراشده، با خروجی قابل مشاهده‌ی سلول‌ها (تحلیل داده، نمودارها، معیار ارزیابی و نتایج مدل)
 ۲. فایل output.csv مطابق ساختار اعلام‌شده
 ۳. ویدیوی حداکثر 5 دقیقه‌ای
- در ویدیو به صورت خلاصه توضیح دهید: تحلیل شما از مسئله، الگوهای مشاهده‌شده در داده، preprocessing انجام‌شده و دلیل آن، ویژگی‌های مهم، مدل انتخابی و دلیل انتخاب، نتیجه‌ی معیار ارزیابی، عوامل مؤثر بر خطای مدل، و در صورت داشتن زمان بیشتر چه بهبودی می‌دادید. نیازی به توضیح خطبه‌خط کد نیست؛ تمرکز ویدیو باید بر منطق حل مسئله و تحلیل نتایج باشد.

لینک فرم سابمیت :

بر روی [لینک](#) کلیک کنید